


Institut Technique des Ursulines – Mons

5^e TT • Mathématiques 4 périodes



Statistique à deux variables

5UAA-1

Quentin Lambotte

Année scolaire 2026 – 2027

Compétences à développer dans ce chapitre

Statistique à deux variables – 5 ^e (4 périodes)				
	Je suis capable de ...	Exercices	Mon niveau de maîtrise	
			en classe	avant (après) le test
Connaître	C1 Décoder le vocabulaire d'une série statistique à deux variables : population, individu, couple de données, les deux variables. C2 Expliquer l'intérêt d'un ajustement : à quoi sert de résumer un nuage de points par une droite. C3 Interpréter le lien entre la forme d'un nuage de points et la valeur du coefficient de corrélation. C4 Expliquer, sur un exemple, la différence entre corrélation et causalité. C5 Expliquer le principe de la méthode des moindres carrés.			
Appliquer	A1 Représenter une série statistique à deux variables par un nuage de points et y placer le point moyen. A2 Déterminer l'équation d'une droite de Mayer. A3 Déterminer l'équation de la droite de régression par la méthode des moindres carrés. A4 Utiliser la calculatrice ou un tableur pour obtenir un ajustement linéaire et un coefficient de corrélation. A5 Calculer une valeur théorique à partir d'un ajustement (interpolation, extrapolation).			
Transférer	T1 Critiquer et commenter des informations statistiques présentées ou calculées, dans un contexte réel.			

Comment lire ces notes

Ces notes alternent des **activités de découverte**, où tu construis toi-même la matière en complétant tableaux, réponses et graphiques, et des encadrés de **théorie**, qui fixent ce qu'il faut retenir. Garde de quoi écrire — et ta calculatrice — à portée de main : les activités sont faites pour être remplies.

L'essentiel du travail se fait **en autonomie**. Les heures en classe servent aux mises en commun, aux points délicats et surtout à l'*interprétation* des résultats. Chaque exercice existe aussi en ligne, avec des **indices** à déplier puis une **solution complète**.

Toutes les données chiffrées de ce cours sont **réelles et sourcées** : la référence est indiquée sous chaque tableau. On ne travaille pas sur des nombres inventés, mais sur des chiffres que tu pourrais retrouver toi-même.

Tu croiseras régulièrement les encadrés suivants :

-  **Activité** une situation à explorer, avec des blancs à compléter ;
- Définition** le sens précis d'un mot nouveau ;
- Propriété** un résultat important à retenir ;
- Exemple** un calcul entièrement résolu, à imiter ;
- Remarque** un point d'attention ou une précision.

Chaque exercice porte un bandeau indiquant sa **difficulté** — de ★☆☆ (application directe) à ★★★ (situation nouvelle à transférer) — et la **compétence** qu'il entraîne (par exemple A3), renvoyant à la grille des pages précédentes.

1

Deux variables, un nuage de points

Jusqu'ici, la statistique que tu as pratiquée portait sur **une seule** grandeur à la fois : la taille des élèves d'une classe, le nombre de frères et sœurs, une série de notes... On la résumait par sa **moyenne**. Mais les questions intéressantes mettent souvent en jeu **deux** grandeurs mesurées sur les mêmes individus, et demandent si elles *vont ensemble* : un pays plus riche vit-il plus longtemps ? Réviser davantage fait-il monter la note ? Ce chapitre apprend à **voir** une telle relation ; les suivants apprendront à la **résumer**, à la **mesurer**, puis à la **critiquer**.

1.1. Réactiver : une variable, une moyenne

Avant de manier deux variables, remettons en place l'outil de base : la moyenne.

Définition 1.1 – moyenne

La **moyenne** d'une série de N valeurs $x_1, x_2, \dots, x_N$ est

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_N}{N}. \quad (1.1)$$

C'est la valeur qui **résume** la série : si toutes les valeurs étaient identiques, ce serait celle-là.

Activité 1.1 – retrouver une moyenne

Voici l'espérance de vie (en années, 2022) dans cinq pays européens.

Pays	Belgique	France	Alle-magne	Pologne	Portugal
Espér. de vie	81,2	82,5	80,6	77,9	81,2

- a) Calcule l'espérance de vie moyenne de ces cinq pays : $\bar{y} =$

 b) L'**étendue** est l'écart entre la plus grande et la plus petite valeur. Ici :

Source : Our World in Data, *Life expectancy*, 2022 (d'après UN, World Population Prospects).

Retiens que la moyenne se calcule aussi **directement à la calculatrice** (touche statistique) ou avec la fonction MOYENNE d'un tableur : dès que la série est longue, c'est ainsi qu'on procède.

1.2. Une série statistique à deux variables

Relevons maintenant, sur chaque pays, **deux** nombres à la fois : son revenu et son espérance de vie.

Définition 1.2 – série statistique à deux variables

On étudie une **population** (ici : des pays). Sur chaque **individu** de cette population, on relève **deux** caractères chiffrés, notés x et y . À chaque individu correspond alors un **couple** $(x_i; y_i)$. L'ensemble de ces couples est une **série statistique à deux variables**.

Le tableau ci-dessous rassemble, pour 14 pays, le **PIB par habitant** (la richesse produite par habitant, en milliers de dollars) et l'**espérance de vie**. Ce sont nos deux variables : x = PIB par habitant, y = espérance de vie.

Pays	PIB/hab. (1000 \$)	Espér. de vie (ans)
Nigéria	5,1	54,1
Inde	7,8	71,7
Brésil	14,6	74,9
Mexique	16,2	74,0
Chine	19,2	78,2
Turquie	27,4	77,6
Portugal	29,0	81,2
Pologne	32,5	77,9
Japon	38,3	84,1
France	39,1	82,5
Belgique	41,9	81,2
Allemagne	46,6	80,6
États-Unis	58,5	78,0

1. Deux variables, un nuage de points

Pays	PIB/hab. (1000 \$)	Espér. de vie (ans)
Norvège	88,4	82,6

Source : Our World in Data, *Life expectancy vs. GDP per capita*, 2022 (PIB par habitant en dollars internationaux constants, d'après la Banque mondiale ; espérance de vie d'après UN WPP).
ourworldindata.org/grapher/life-expectancy-vs-gdp-per-capita

Remarque 1.1

Le choix de x et de y n'est pas neutre : on met en x (abscisse) la variable que l'on soupçonne d'**expliquer** l'autre, et en y (ordonnée) celle que l'on cherche à comprendre. Ici, on se demande si la richesse (x) éclaire l'espérance de vie (y).

1.3. Le nuage de points

Un tableau de 14 couples est difficile à lire d'un coup d'œil. Pour voir la relation, on dessine.

Définition 1.3 – nuage de points

Le **nuage de points** d'une série $(x_i; y_i)$ est l'ensemble des points de coordonnées $(x_i; y_i)$ placés dans un repère. Chaque point représente un individu. On ne relie **pas** les points : ils ne forment pas une courbe, mais un semis que l'on interprète globalement.

Activité 1.2 – lire le nuage revenu – espérance de vie

Voici le nuage des 14 pays du tableau (x = PIB par habitant en milliers de dollars, y = espérance de vie en années).




Figure 1.1 – Espérance de vie en fonction du PIB par habitant (14 pays, 2022).

a) **Sens.** Quand le PIB par habitant augmente, l'espérance de vie a-t-elle plutôt tendance à augmenter ou à diminuer ?

b) **Forme.** Les points sont-ils parfaitement alignés sur une droite ?

c) **Point atypique.** Un pays riche s'écarte nettement de la tendance : lequel, et pourquoi est-ce frappant ?

d) **Point moyen.** À la calculatrice, calcule les deux moyennes, puis place sur le graphique le point $G(\bar{x}; \bar{y})$ (une croix). $\bar{x} \approx \dots\dots\dots$ $\bar{y} \approx \dots\dots\dots$

1.4. Le point moyen

Le point que tu viens de placer porte un nom.

Définition 1.4 – point moyen

Le **point moyen** d'une série à deux variables est le point G de coordonnées

$$G(\bar{x}; \bar{y}), \quad (1.2)$$

où $\bar{x}$ et $\bar{y}$ sont les moyennes des deux variables. Il marque le **centre** du nuage : c'est le « pays moyen » de la série.

Remarque 1.2

G n'est pas forcément l'un des points du nuage : aucun pays réel n'a exactement (33, 2; 77, 0). C'est un point *calculé*, qui résume l'ensemble. Nous le retrouverons au chapitre suivant : toute droite qui résume bien le nuage passera par G.

1.5. Décrire un nuage

Décrire un nuage, ce n'est pas le calculer : c'est le **lire**. Trois questions suffisent, et une quatrième affine.

- **Sens** — quand x augmente, y tend-il à augmenter (nuage **croissant**), à diminuer (nuage **décroissant**), ou ni l'un ni l'autre (aucun lien) ?
- **Forme** — les points sont-ils proches d'une **droite** (relation *linéaire*) ou d'une courbe ?

1. Deux variables, un nuage de points

- **Dispersion** – sont-ils bien **resserrés** autour de cette tendance, ou très **éparpillés** ?
- **Points atypiques** – un ou plusieurs individus s'écartent-ils nettement du reste ?

Ces observations préparent la suite : si les points sont proches d'une droite, on pourra les **résumer** par une droite (chapitre 2) ; et l'on saura bientôt **mesurer** par un nombre à quel point le lien est fort (chapitre 3).

1.6. Exercices

Exercice 1.1

Décoder | ★★☆☆ | C1

Un professeur relève, pour 6 élèves, le nombre d'heures de révision avant un test (x) et la note obtenue sur 20 (y).

- Quelle est la population étudiée ?
- Quels sont les deux caractères relevés ?
- Combien de couples $(x_i; y_i)$ la série compte-t-elle ?
- Écris le couple correspondant à un élève ayant révisé 3 h et obtenu 12 .


Exercice 1.2

Représenter | ★★☆☆ | A1

On reprend six pays du tableau (x = PIB/hab. en milliers de \$, y = espérance de vie).

Pays	Éthio- pie	Inde	Chine	Turquie	Bel- gique	Nor- vège
x	2,3	7,8	19,2	27,4	41,9	88,4
y	66,9	71,7	78,2	77,6	81,2	82,6

- Trace le nuage de points dans le repère ci-dessous.
- Calcule $\bar{x}$ et $\bar{y}$ (calculatrice), puis place le point moyen G .



$\bar{x} \approx 31,2$; $\bar{y} \approx 76,4$. Source des données : Our World in Data, 2022.

Exercice 1.3

Interpréter | ★★☆☆ | C3

Associe chacun des trois nuages ci-dessous à la description qui lui convient : (1) lien croissant et resserré ; (2) lien décroissant ; (3) aucun lien visible.




Figure 1.2 - Nuage A




Figure 1.3 - Nuage B




Figure 1.4 - Nuage C

A $\leftrightarrow$ B $\leftrightarrow$ C $\leftrightarrow$

Exercice 1.4

Critiquer | ★★☆☆ | C2

Reprends le nuage revenu – espérance de vie de l'activité. Un élève affirme : « Il suffit d'être riche pour vivre vieux. » En t'appuyant sur le **sens**, la **forme** et le **point atypique** du nuage, explique en quelques lignes pourquoi cette phrase est trop simple.

2

Ajuster un nuage par une droite

Au chapitre précédent, on a appris à *voir* un nuage. Quand ses points s'organisent autour d'une tendance à peu près **droite**, on peut aller plus loin : tracer **une** droite qui résume le nuage. C'est l'**ajustement linéaire**. Une fois cette droite trouvée, elle remplace des dizaines de points par une seule équation — pratique pour décrire la tendance et, plus tard, faire des prévisions.

2.1. Pourquoi ajuster ?

Résumer un nuage par une droite $y = ax + b$, c'est utile pour trois raisons :

- **décrire** la tendance d'un seul coup (a dit dans quel sens et à quelle vitesse y évolue quand x augmente) ;
- **prévoir** une valeur de y pour un x non observé (chapitre 4) ;
- **comparer** deux situations à l'aide d'un même repère.

Mais attention : ajuster n'a de sens que si le nuage est *à peu près* aligné. Forcer une droite sur un nuage sans tendance ne donne rien d'utile — nous apprendrons au chapitre 3 à mesurer si le lien est assez fort pour que la droite soit crédible.

2.2. Une série qui évolue : l'écart salarial

Suivons un vrai indicateur de société : l'**écart salarial** entre les femmes et les hommes en Belgique, c'est-à-dire de combien de pour cent le salaire horaire moyen des femmes est inférieur à celui des hommes.

Année	$t = \text{année} - 2006$	Écart horaire (%)
2006	0	9,5
2010	4	10,2
2015	9	6,4

Année	$t = \text{année} - 2006$	Écart horaire (%)
2017	11	5,8
2020	14	3,2
2022	16	0,7

Source : Eurostat, *Gender pay gap in unadjusted form* (code sdg_05_20), écart salarial horaire, Belgique.
 Pour simplifier les calculs, on compte les années à partir de 2006 (colonne t).

Activité 2.1 – voir la tendance

Voici le nuage de ces six couples $(t; y)$.




Figure 2.1 – Écart salarial horaire femmes-hommes en Belgique, depuis 2006.

- Le nuage est-il croissant ou décroissant ?
- En une phrase, que raconte-t-il ?

2.3. Le point moyen, pivot de l'ajustement

Rappelle-toi le **point moyen** $G(\bar{t}; \bar{y})$. Il joue un rôle central ici :

Propriété 2.1 – le point moyen est sur la droite

Toute droite d'ajustement raisonnable – qu'on la construise par la méthode de Mayer ou par celle des moindres carrés – **passse par le point moyen** G . C'est le point d'équilibre du nuage.

Pour notre série : $\bar{t} = 54 \div 6 = 9$ et $\bar{y} = 35,8 \div 6 \approx 5,97$. Donc $G(9; 5,97)$.

2.4. La droite de Mayer

Première méthode, entièrement « à la main ». L'idée : couper le nuage en deux groupes, trouver le point moyen de chacun, et relier ces deux points.

Définition 2.1 – droite de Mayer

On range les points par abscisse croissante et on les partage en **deux sous-séries** de même taille. On calcule le point moyen G_1 de la première et G_2 de la seconde. La **droite de Mayer** est la droite $(G_1 G_2)$.

L'idée a du sens : chaque sous-série est **résumée** par son propre point moyen (G_1, G_2) , un « représentant » de sa moitié du nuage ; relier ces deux représentants donne la direction générale. Et comme G_1 et G_2 encadrent le centre du nuage, la droite passe tout près du point moyen global G .

Exemple 2.1 – Mayer sur l'écart salarial

Nos six points sont déjà rangés. On coupe en deux groupes de trois.

Groupe 1 : $(0; 9,5)$, $(4; 10,2)$, $(9; 6,4)$.

$G_1 = (13,0 \div 3; 26,1 \div 3) \approx (4,33; 8,70)$.

Groupe 2 : $(11; 5,8)$, $(14; 3,2)$, $(16; 0,7)$.

$G_2 = (41 \div 3; 9,7 \div 3) \approx (13,67; 3,23)$.

La pente :

$$a = \frac{3,23 - 8,70}{13,67 - 4,33} = \frac{-5,47}{9,33} \approx -0,59. \quad (2.1)$$

L'ordonnée à l'origine, en écrivant que la droite passe par G_1 :

$$8,70 = -0,59 \times 4,33 + b \Rightarrow b \approx 11,2. \quad (2.2)$$

Droite de Mayer :

$$y \approx -0,59 t + 11,2. \quad (2.3)$$

Remarque 2.1


On peut vérifier que cette droite passe bien (à l'arrondi près) par le point moyen $G(9; 5,97)$:
 $-0,59 \times 9 + 11,2 \approx 5,9$. ✓

2.5. Faire parler les écarts à la moyenne

Avant de chercher « la meilleure droite », posons une question plus simple : comment *un seul nombre* pourrait-il dire si x et y varient ensemble ? L'idée est de regarder chaque point par rapport au **point moyen G** .

Activité 2.2 – le signe qui révèle le sens

Traçons par G deux droites : la verticale $x = \bar{x}$ et l'horizontale $y = \bar{y}$. Elles partagent le plan en quatre zones.



Pour chaque point, on note son **écart en x** ($x_i - \bar{x}$) et son **écart en y** ($y_i - \bar{y}$).

a) Quel est le signe de leur **produit** selon la zone ? Un point en haut à droite de G a ses deux écarts positifs, donc un produit ; un point en haut à gauche a un produit

b) Vérifions-le sur quatre années de l'écart salarial ($\bar{x} = 9$, $\bar{y} \approx 5,97$). Complète les signes :

Année	signe de $x_i - \bar{x}$	signe de $y_i - \bar{y}$	signe du produit
2006			
2010			
2020			
2022			

c) Tous les produits sont négatifs : le nuage est donc plutôt Si, au contraire, les produits étaient majoritairement positifs, le nuage serait

Ce que tu viens d'examiner point par point porte un nom : en faisant la **moyenne** de tous ces produits, on obtient la **covariance**.

Définition 2.2 – covariance

La **covariance** de x et y est la moyenne des produits des écarts à leurs moyennes :


$$\text{cov}(x, y) = \frac{1}{N} \sum (x_i - \bar{x})(y_i - \bar{y}). \quad (2.4)$$

Son **signe** donne le **sens** du lien : **positive** si x et y augmentent ensemble, **négative** s'ils varient en sens contraire, proche de 0 s'il n'y a pas de tendance nette.

2.6. La méthode des moindres carrés

La droite de Mayer est simple, mais elle ne regarde que deux points moyens. La méthode des **moindres carrés** utilise *tous* les points, en rendant la droite « aussi proche que possible » de l'ensemble.

Pour chaque point, on mesure l'**écart vertical** entre le point et la droite (on l'appelle un **résidu**). Une droite est d'autant meilleure que ces écarts sont petits.



Définition 2.3 – droite de régression (moindres carrés)

La **droite de régression** par la méthode des moindres carrés est l'unique droite $y = ax + b$ qui rend la **plus petite possible** la **somme des carrés des résidus**. On élève les écarts au carré pour que les écarts positifs et négatifs ne se compensent pas, et pour pénaliser les gros écarts. Cette droite passe elle aussi par le point moyen G .

On cherche la droite qui rend **minimale** la somme des carrés des résidus. On admet le résultat, mais sa forme se *comprend* à partir de ce qui précède :

Propriété 2.2 – pente de la droite de régression

$$a = \frac{\text{cov}(x, y)}{\text{variance}(x)} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \quad b = \bar{y} - a\bar{x}. \quad (2.5)$$

Au numérateur, la **co-variation** de x et y (leur tendance à bouger ensemble, que tu viens de mesurer) ; au dénominateur, l'**étalement** de x seul. La pente dit donc « de combien y bouge quand x bouge ». Et comme $b = \bar{y} - a\bar{x}$, la droite passe **par le point moyen G** .

Reste à calculer $\text{cov}(x, y)$ et $\text{variance}(x)$. On pourrait revenir aux écarts un à un, mais il existe une écriture **équivalente** bien plus rapide, qui évite la colonne des écarts.

Propriété 2.3 – formules de calcul

$$\text{variance}(x) = \frac{1}{N} \sum x_i^2 - (\bar{x})^2 \quad \text{cov}(x, y) = \frac{1}{N} \sum x_i y_i - \bar{x} \bar{y}. \quad (2.6)$$

En mots : **moyenne des carrés – carré de la moyenne** pour la variance ; **moyenne des produits – produit des moyennes** pour la covariance. L'écart-type $\sigma_x = \sqrt{\text{variance}(x)}$ mesure la dispersion de x .

Remarque 2.2

Pourquoi « moyenne des carrés – carré de la moyenne » mesure-t-il la dispersion ? Si toutes les valeurs étaient **égales**, la moyenne des carrés vaudrait exactement le carré de la moyenne : la variance serait nulle. Plus les valeurs s'écartent de leur moyenne, plus la moyenne des carrés **dépasse** le carré de la moyenne – et c'est cet excédent qui mesure l'étalement. La covariance suit la même idée, avec des *produits* à la place des carrés.

Ces formules ne réclament qu'un tableau à **quelques colonnes** : les valeurs, leurs carrés et leurs produits – aucune colonne d'écarts.

Exemple 2.2 – la pente depuis un seul tableau

On dresse le tableau pour l'écart salarial :

t	y	t^2	y^2	ty
0	9,5	0	90,25	0
4	10,2	16	104,04	40,8
9	6,4	81	40,96	57,6
11	5,8	121	33,64	63,8
14	3,2	196	10,24	44,8
16	0,7	256	0,49	11,2

Sommes : $\sum t = 54$, $\sum y = 35,8$, $\sum t^2 = 670$, $\sum y^2 = 279,62$, $\sum ty = 218,2$, avec $N = 6$.

Moyennes : $\bar{t} = 54 \div 6 = 9$ et $\bar{y} = 35,8 \div 6 \approx 5,97$.

$$\text{variance}(t) = 670 \div 6 - 9^2 \approx 111,7 - 81 = 30,7. \quad (2.7)$$

$$\text{cov}(t, y) = 218,2 \div 6 - 9 \times 5,97 \approx 36,4 - 53,7 = -17,3. \quad (2.8)$$

$$a = \frac{\text{cov}(t, y)}{\text{variance}(t)} = \frac{-17,3}{30,7} \approx -0,57, \quad b = 5,97 - (-0,57) \times 9 \approx 11,1. \quad (2.9)$$

Droite de régression : $y \approx -0,57 t + 11,1$ – très proche de la droite de Mayer ($-0,59 t + 11,2$). La colonne y^2 resservira au chapitre 3 pour le coefficient de corrélation.

Activité 2.3 – obtenir la droite à la calculatrice

2. Ajuster un nuage par une droite

En pratique, on ne calcule pas ces sommes à la main : la calculatrice le fait. Sur ta machine, entre dans le mode **statistiques à deux variables**, saisis les couples $(t; y)$, puis lis la **régression linéaire** $(ax + b)$. Note ce que tu obtiens : $a \approx \dots\dots\dots$ $b \approx \dots\dots\dots$

Voici la droite superposée au nuage :




Figure 2.2 – Nuage et droite de régression $y \approx -0,57 t + 11,1$.

2.7. Exercices

Exercice 2.1

Calculer | ★☆☆ | A2

On donne cinq points, déjà rangés : $(1; 2)$, $(2; 5)$, $(3; 5)$, $(4; 8)$, $(5; 10)$. Le point du milieu $(3; 5)$ est laissé de côté pour équilibrer les groupes.

- Calcule G_1 (les deux premiers points) et G_2 (les deux derniers).
- Détermine la pente puis l'équation de la droite de Mayer.
- Vérifie qu'elle passe par le point moyen G des cinq points.

Exercice 2.2

Calculer | ★☆☆ | A3

Reprends les cinq points de l'exercice précédent. Dresse un tableau à colonnes x_i , y_i , x_i^2 , $x_i y_i$ (quatre colonnes suffisent pour la pente), calcule $\text{variance}(x)$ et $\text{cov}(x, y)$ par les **formules développées**, puis déduis-en l'équation de la **droite de régression**. Compare sa pente à celle de la droite de Mayer : sont-elles proches ?

Exercice 2.3

Interpréter | ★☆☆ | C5

Un camarade a tracé « au jugé » une droite qui passe *au-dessus* de tous les points d'un nuage. En raisonnant sur les **résidus**, explique pourquoi ce ne peut pas être la droite des moindres carrés.

Exercice 2.4

Appliquer | ★★☆☆ | A4

On relève, pour huit pays, le PIB par habitant x (milliers de \$) et l'espérance de vie y (données du chapitre 1, Our World in Data 2022).

x	7,8	14,6	19,2	27,4	32,5	39,1	46,6	58,5
y	71,7	74,9	78,2	77,6	77,9	82,5	80,6	78,0

- À la calculatrice, donne l'équation de la droite de régression.
- La pente est positive : qu'est-ce que cela signifie, concrètement, sur le lien entre richesse et espérance de vie ?

Mesurer la liaison : le coefficient de corrélation

On sait tracer une droite d'ajustement. Mais une droite peut se tracer sur *n'importe quel* nuage, même un nuage sans tendance : rien ne dit qu'elle a un sens. Il nous faut un **nombre** qui réponde à la question « les points sont-ils vraiment proches d'une droite ? ». Ce nombre est le **coefficient de corrélation**.

3.1. Un nombre entre -1 et 1

Définition 3.1 – coefficient de corrélation linéaire

Le **coefficient de corrélation linéaire**, noté r , est un nombre toujours compris entre -1 et 1 qui mesure à quel point les points d'un nuage sont proches d'une **droite**.

- le **signe** de r donne le **sens** : $r > 0$ pour un nuage croissant, $r < 0$ pour un nuage décroissant ;
- $|r|$ **proche de 1** : les points sont presque alignés (lien fort) ; $|r|$ **proche de 0** : aucun alignement (lien linéaire faible ou nul).

On le calcule par $r = \frac{\text{covariance}(x,y)}{\sigma_x \sigma_y}$, mais en pratique c'est la **calculatrice** qui le donne, en même temps que la droite de régression.

Pourquoi diviser par $\sigma_x \sigma_y$? La covariance seule dépend des **unités** (des euros, des années, des degrés...) : sa valeur peut être énorme ou minuscule sans que le lien soit pour autant plus ou moins fort. En la divisant par l'étalement de chaque variable, on efface les unités : r devient un nombre **sans dimension**, toujours entre -1 et 1 , donc **comparable** d'un contexte à l'autre.

Cette division explique aussi *pourquoi* r ne dépasse jamais 1 en valeur absolue : la covariance est au maximum égale à $\sigma_x \sigma_y$ (ce maximum est atteint quand les points sont parfaitement alignés).

Le coefficient r compare donc la co-variation **réelle** à la co-variation **maximale possible** — d'où $-1 \leq r \leq 1$, et $r = \pm 1$ pour un alignement parfait.

Pour interpréter $|r|$, un ordre de grandeur utile (à ne pas prendre au pied de la lettre) : au-delà de 0,9, lien **très fort** ; entre 0,7 et 0,9, **fort** ; entre 0,5 et 0,7, **moyen** ; en dessous de 0,5, **faible**.

Remarque 3.1

r ne mesure **que** le lien *linéaire*. Un nuage en forme de U (parabole) peut avoir $r \approx 0$ alors que le lien entre x et y est évident : il n'est simplement pas *droit*. De même, r ne dit rien de la **pente** : une droite très inclinée et une droite presque plate peuvent toutes deux donner $r = 1$.

3.2. Lire r sur un nuage

Activité 3.1 — associer un nuage à son coefficient

Associe chacun des quatre nuages à l'une des valeurs de r proposées :

0,98 0,55 $-0,88$ 0,05. (3.1)




Figure 3.1 – Nuage A




Figure 3.2 – Nuage B




Figure 3.3 – Nuage C




Figure 3.4 – Nuage D

A $\leftrightarrow$ B $\leftrightarrow$ C $\leftrightarrow$ D $\leftrightarrow$

3.3. Calculer r

Exemple 3.1 – la corrélation de l'écart salarial

Reprenons la série « écart salarial » du chapitre 2 (les six couples $(t; y)$). À la calculatrice, on lit

$$r \approx -0,94. \quad (3.2)$$

Le signe négatif confirme la **baisse** ; la valeur, très proche de -1 , confirme que les points sont **bien alignés** : la droite de régression était donc pleinement justifiée. On peut le retrouver depuis le tableau du chapitre 2 : $\text{cov}(t, y) \approx -17,3$, $\sigma_t = \sqrt{30,7} \approx 5,54$, $\sigma_y = \sqrt{279,62 \div 6 - 5,97^2} \approx 3,32$, d'où

$$r = \frac{\text{cov}(t, y)}{\sigma_t \sigma_y} \approx \frac{-17,3}{5,54 \times 3,32} \approx -0,94. \quad (3.3)$$

3.4. Corrélation n'est pas causalité

Un r proche de 1 dit que deux variables **varient ensemble**. Il ne dit *jamais*, à lui seul, que l'une **cause** l'autre. L'exemple suivant le montre de façon spectaculaire.

Activité 3.2 – margarine et divorces

Aux États-Unis, entre 2000 et 2009, on a relevé la consommation de margarine par habitant (x , en livres) et le taux de divorces dans l'État du Maine (y , pour 1000 habitants).

x	8,2	7,0	6,5	5,3	5,2	4,0	4,6	4,5	4,2	3,7
y	5,0	4,7	4,6	4,4	4,3	4,1	4,2	4,2	4,2	4,1




Figure 3.5 – Margarine et divorces (Maine), 2000–2009 : $r \approx 0,99$.

Source : USDA (margarine) et CDC, National Vital Statistics (divorces), compilés par T. Vigen, *Spurious Correlations*.

- a) Que vaut approximativement r ? Le lien est-il fort ?
- b) Manger moins de margarine réduit-il vraiment les divorces ?

Quand deux variables sont corrélées, il y a **trois explications possibles**, et il faut se demander laquelle est vraie :

- **Cause à effet** — x agit réellement sur y (p. ex. plus on chauffe une pièce, plus la température monte).
- **Variable cachée** — un troisième facteur agit sur x et sur y (p. ex. dans une grande ville, il y a à la fois plus de policiers et plus de délits : la vraie cause commune est la *taille* de la ville).
- **Coïncidence** — pur hasard, fréquent quand on cherche des liens partout (margarine et divorces).

Remarque 3.2

C'est pourquoi il faut se méfier des débats où l'on relie deux phénomènes de société en montrant qu'ils « vont ensemble ». Un nuage de points ne suffit jamais à établir une cause : il faut écarter les variables cachées et le hasard.

3.5. Exercices

Exercice 3.1

Interpréter | ★★☆☆ | C3

Pour chaque valeur de r , décris le nuage correspondant (sens et force du lien) :

- $r = 0,97$
- $r = -0,4$
- $r = -0,99$
- $r = 0,02$

Exercice 3.2

Critiquer | ★★☆☆ | C4

On observe une corrélation positive forte entre le nombre de coups de soleil et le nombre de noyades, semaine après semaine, sur une plage.

- Est-il raisonnable de dire que les coups de soleil provoquent les noyades ?
- Quelle **variable cachée** explique le lien ?
- Propose une phrase correcte pour décrire la situation.

3. Mesurer la liaison : le coefficient de corrélation

Exercice 3.3

Critiquer | ★★☆☆ | C4

Un article titre : « Les villes qui comptent le plus de policiers sont celles où l'on enregistre le plus de délits : la police serait-elle inefficace ? » En t'appuyant sur la notion de variable cachée, explique en quelques lignes pourquoi ce titre confond corrélation et causalité.

Exercice 3.4

Appliquer | ★★☆☆ | A4

Reprends les huit pays de l'exercice du chapitre 2 (PIB par habitant et espérance de vie). À la calculatrice, calcule le coefficient de corrélation. Le lien est-il assez fort pour qu'une droite d'ajustement soit justifiée ?

4

Utiliser un ajustement, et le critiquer

Une droite d'ajustement ne sert pas qu'à décrire : elle permet de **prévoir** une valeur là où on n'a pas mesuré. Mais toute prévision a ses limites, et savoir les repérer — chez soi comme dans un article — est sans doute la compétence la plus utile de ce chapitre.

4.1. Prévoir : interpolation et extrapolation

Définition 4.1 — interpolation, extrapolation

À partir de la droite de régression $y = ax + b$, on peut estimer un y pour une valeur de x non mesurée.

- **Interpoler**, c'est estimer à l'intérieur de l'intervalle des données observées : assez sûr.
- **Extrapoler**, c'est estimer à l'extérieur (avant la première donnée ou après la dernière) : beaucoup plus risqué.

Exemple 4.1 — prévoir l'écart salarial

On reprend la droite de régression du chapitre 2 : $y \approx -0,57 t + 11,1$ (avec t = année – 2006, données 2006 – 2022).

Interpolation — estimer l'écart en 2013 ($t = 7$, entre 2006 et 2022) :

$$y \approx -0,57 \times 7 + 11,1 \approx 7,1 \%. \quad (4.1)$$

Extrapolation — en quelle année le modèle prévoit-il un écart nul ? On résout $0 = -0,57 t + 11,1$, soit

$$t \approx \frac{11,1}{0,57} \approx 19,5, \quad (4.2)$$

c'est-à-dire vers 2025 – 2026. C'est une extrapolation : on sort de l'intervalle des données.

Activité 4.1 – jusqu'où prolonger la droite ?

La droite est prolongée ci-dessous au-delà de la dernière donnée (2022, soit $t = 16$).




Figure 4.1 – Droite de régression prolongée : où coupe-t-elle l'axe ?

- a) Vers quelle valeur de t la droite atteint-elle 0 ?
- b) Peut-on en conclure qu'il n'y aura *plus aucune* inégalité salariale en 2025 ? Réfléchis avant de répondre à la section suivante.

4.2. Les limites de l'extrapolation

⚠ Extrapoler, c'est parier

Prolonger une droite au-delà des données suppose que la tendance **continue à l'identique**. Ce n'est jamais garanti :

- la tendance peut **ralentir** ou se **stabiliser** (ici, l'écart pourrait s'approcher de 0 sans jamais l'atteindre) ;
- un chiffre proche de 0 peut **cacher** d'autres inégalités : l'écart *horaire* non ajusté ignore le temps partiel (surtout féminin), la ségrégation des métiers et le plafond de verre ; mesuré sur les *revenus annuels*, l'écart reste bien plus élevé ;
- le nuage lui-même n'est pas parfaitement droit (le point de 2010 remonte).

Une extrapolation est une **hypothèse**, pas une certitude.

4.3. Un vrai document à critiquer

La statistique à deux variables ne sert pas qu'à des courbes : elle sert à **trancher des débats de société** avec des chiffres. Voici une étude belge récente.

Exemple 4.2 — tester la discrimination à l'embauche

Pour mesurer la discrimination, des chercheurs ont utilisé le **testing par correspondance** : ils envoient à de vraies offres d'emploi des paires de candidatures **identiques** (mêmes diplômes, même expérience), qui ne diffèrent que par un détail — ici, l'origine suggérée par le nom — puis comparent les taux de réponse positive.

À Bruxelles, 864 candidatures (432 paires) ont été envoyées entre avril 2023 et février 2024. Résultats :

- taux de réponse positive **global** : 36% ;
- un candidat d'origine **marocaine** (hors UE) reçoit 9,5 points de pourcentage de réponses positives **en moins** qu'un candidat d'origine belge, à CV identique ;
- un candidat d'origine **polonaise** (UE) : **aucune** discrimination détectée.

Source : I. Tobback, M. Barslund, S. Baert & P.-P. Verhaeghe, *Discrimination sur le marché du travail bruxellois*, Service public régional de Bruxelles, 2024.

Propriété 4.1 — quand la corrélation devient une cause

Un simple nuage ne prouve pas la causalité (chapitre 3). Mais un **testing** est une **expérience** : comme les deux CV sont identiques et que seule l'origine change, il n'y a plus de variable cachée possible. La différence observée peut alors être **attribuée** à l'origine. C'est la force d'une expérience bien construite sur une simple observation.

Activité 4.2 — lire l'étude en citoyen

a) Que signifie concrètement « 9,5 points de pourcentage en moins » ?

b) Pourquoi peut-on ici parler de **cause**, alors qu'un nuage ne le permettrait pas ?

c) Quelles **limites** garderais-tu en tête avant de généraliser ?

4.4. Exercices

Exercice 4.1

Appliquer | ★★☆☆ | A5

Une droite de régression relie le nombre d'heures de révision x à la note y (sur 20) : $y = 1,5x + 6$, établie pour des élèves ayant révisé de 1 à 8 heures.

- Estime la note d'un élève ayant révisé 5 h.
Interpolation ou extrapolation ?
- Le modèle prévoit-il une note correcte pour 12 h de révision ? Commente.

Exercice 4.2

Critiquer | ★★☆☆ | T1

Un journal affiche deux graphiques du *même* jeu de données. Sur le premier, l'axe vertical va de 0 à 100 ; la courbe paraît presque plate. Sur le second, l'axe vertical va de 48 à 52 ; la même courbe paraît grimper en flèche.

- Les données sont-elles différentes ?
Qu'est-ce qui change ?
- Quel graphique est trompeur, et pourquoi ?
- Quelle règle proposerais-tu pour un axe vertical honnête ?

Exercice 4.3

Transférer | ★★★ | T1

Pour chacune des affirmations, dis s'il s'agit d'une **corrélation** ou d'une **causalité** établie, et justifie en une phrase.

- « Dans un testing, à CV identique, changer le prénom fait chuter le taux de rappel. »
- « Les pays où l'on consomme le plus de chocolat comptent le plus de prix Nobel. »
- « Après avoir augmenté le nombre de contrôles fiscaux, l'administration a récupéré davantage d'impôts éludés. »

Exercice 4.4

Transférer | ★★★ | T1

On te donne le nuage « PIB par habitant – espérance de vie » du chapitre 1 et sa droite de régression. Rédige un court paragraphe (5 – 6 lignes) qui : décrit le lien, donne l'ordre de grandeur du coefficient de corrélation attendu, et **nuance** toute conclusion trop rapide du type « il suffit d'enrichir un pays pour que ses habitants vivent plus longtemps ».